

ECON-520

Ciencia de Datos para Economía y Negocios
Clases 09-11

Viktoriya Semeshenko
Sergio De Raco



<https://bit.ly/e520-2026C1-textmining>

Text Mining

¿Qué es **text mining**?

- [Wiki](#) dice:


Text mining, text data mining (TDM) or text analytics is the process of deriving high-quality **information** from **text**.

It involves "the discovery by computer of new, previously unknown information, by automatically extracting information from different written resources."

- [IBM](#) dice:


Text mining, also known as **text data mining**, is the **process of transforming unstructured text into a structured format** to **identify meaningful patterns and new insights**. You can use text mining to analyze vast collections of textual materials to capture key concepts, trends and hidden relationships.

Algunas áreas de TM:



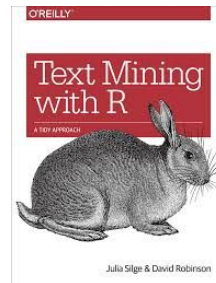
Text Mining

- Introduction to tidytext



Text Mining with R: A Tidy Approach


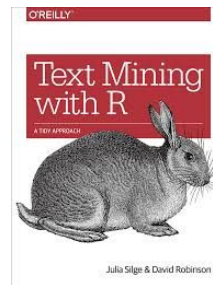
- textual data: alphanumeric characters (strings)
- corpus: a collection of text units (documents)
- token: a *meaningful unit of text*, most often a word, interesting for analysis
- [dtm](#)



Material + Referencias TM

Biblio de referencia

- [Text Mining](#) @Wikipedia
- Silge and Robinson (2017), [Text Mining with R: A Tidy Approach](#)
- Hastie, Tibshirani and Friedman (2017), [The Elements of Statistical Learning: Data Mining, Inference, and Prediction](#). (2nd edition, 12th printing)



Bonus


- [Kurt Vonnegut](#), [The Shape of Stories](#)

Frecuencia de palabras y documentos

Enfoques para tratar con las palabras muy frecuentes (alto tf , poco informativas)

- **stopwords**: quitarlas del análisis, pero alguna en algún doc puede ser muy informativas
- **frecuencia inversa de términos en documentos** (idf): combinado en $tf-idf$ (producto de ambos), un estadístico que mide la frecuencia de un término ajustado por cuán raro es su utilización
- **Ley de Zipf (linguista)**: la frecuencia de aparición de una palabra es proporcionalmente inversa a su ranking (ley de potencias)

$$\text{frequency} \propto \frac{1}{\text{rank}}$$



Ejercicios

- Explorar y analizar estos textos con las rutinas vistas en clase
 - <http://mirrors.xmission.com/gutenberg/1/10/10-0.txt>
 - <https://ciudadseva.com/autor/julio-cortazar/cuentos/>
 - Libros en [Project Gutenberg](#) (paquete [gutenbergr](#))
 - Buscar un corpus que les interese