

ECON-520

Ciencia de Datos para Economía y Negocios Clase 16


Viktoriya Semeshenko
Sergio De Raco



<https://bit.ly/ECON5202026C1-Clase16>

Club de Karate de Zachary

- Una red social a la que se ha prestado especial atención en el contexto de la detección de comunidades, que recoge los vínculos entre 34 miembros de un club de kárate
- Dado el reducido tamaño del club, todos sus miembros se conocían entre sí. Para descubrir las verdaderas relaciones entre los socios del club, el sociólogo Wayne Zachary documentó 78 vínculos de pares entre socios que interactuaban habitualmente **fuera del club**.
- El interés del conjunto de datos se debe a un acontecimiento singular: Un conflicto entre el presidente del club y el instructor dividió al club en dos. Aproximadamente la mitad de los socios seguían al instructor y la otra mitad al presidente, una ruptura que desveló la verdad básica, que representa la estructura comunitaria subyacente del club (a). Hoy en día, los algoritmos de búsqueda de comunidades suelen ponerse a prueba en función de su capacidad para inferir estas dos comunidades a partir de la estructura de la red antes de la división.



Redes en R con `igraph`

- [Zachary Karate Club Analysis](#)
- [Capitulo 4 SAND](#)
 - Statistical Analysis of Network Data with R ([SAND](#))

Biblio de referencia: Barabási: [Network Science book](#)

Coeficiente de Clustering

- capta el grado en que los vecinos de un nodo se enlazan entre sí
- para el nodo i con grado k_i , el coeficiente de clustering local:

$$C_i = \frac{2L_i}{k_i(k_i - 1)}$$

donde L_i representa el número de enlaces entre k_i vecinos del nodo i


- $C_i \in [0...1]$ es la probabilidad de que los dos vecinos de un nodo se enlacen entre sí
- $C_i = 0$ si ninguno de los vecinos del nodo i está vinculado entre sí
- $C_i = 1$ si los vecinos del nodo i forman un grafo completo
- $C_i = 0.5 \rightarrow 50\%$ proba de que los dos vecinos de un nodo estén vinculados entre sí

Coeficiente de Clustering Medio


- $\langle C \rangle$ es la probabilidad de que dos vecinos de un nodo seleccionado aleatoriamente se enlacen entre sí

$$\langle C \rangle = \frac{1}{N} \sum_{i=1}^N C_i$$


Coeficiente de Clustering




$$C_i = 1$$



$$C_i = 1/2$$



$$C_i = 0$$



$$\langle C \rangle = \frac{13}{42} \approx 0.310$$

$$C_{\Delta} = \frac{3}{8} = 0.375$$

Coeficiente Global de Clustering

- (o transitividad) mide la probabilidad de que dos nodos conectados a un tercer nodo también estén conectados entre sí, formando triángulos en la red.
- Se calcula:

$$C = \frac{3 \text{ Numero de triangulos en la red}}{\text{Numero total de triadas abiertas y cerradas}}$$




donde

- una **triada** es un conjunto de tres nodos donde al menos dos están conectados
 - una triada cerrada es un **triángulo**
 - una triada abierta ocurre cuando un nodo está conectado a otros dos, pero estos dos no están conectados entre sí

*La multiplicación por 3 se debe a que cada triángulo contiene exactamente tres triadas cerradas


Distribución de Grado: Hubs

- La distribución de grado es una métrica fundamental para entender cómo están distribuidas las conexiones en una red




Distribución de Grado: Hubs

Network	Nodes	Links	Directed / Undirected	N	L	$\langle K \rangle$
Science Collaboration	Scientists	Co-authorships	Undirected	23,133	93,437	8.08
WWW	Webpages	Links	Directed	325,729	1,497,134	4.60
Protein Interactions	Proteins	Binding	Undirected	2,018	2,930	2.90




- Los **hubs** generalmente tienen una **alta centralidad de intermediación**, pero esto no garantiza que tengan una **alta centralidad de cercanía**.



Caminos y Distancias


¿Cuál es la **distancia** entre dos páginas web o entre dos personas que no se conocen?

- La distancia física es reemplazada por la **longitud del camino** (*path length*).
- La longitud es un camino que **recorre** los enlaces de la red. La longitud de un camino representa **el número de enlaces** que contiene el camino



distancia → recorre → camino → métrica de centralidad

Caminos distintos



- Camino
 - Una secuencia de nodos de modo que cada nodo esté conectado al siguiente nodo a lo largo del camino mediante un enlace. (Ej: $1 \rightarrow 2 \rightarrow 5 \rightarrow 4 \rightarrow 3$; $d=4$)
- Camino corto
 - El camino con la distancia más corta entre dos nodos (puede ser no único).
- Diámetro
 - El camino más corto máximo, o la distancia entre los dos nodos más lejanos
 - Ej: el diámetro entre nodos 1 y 4, $d_{max}=3$.
- Camino corto promedio $\langle d \rangle$
 - El promedio de caminos cortos entre todos pares de nodos. (Ej: $\langle d \rangle=1.6$)

Medidas de Centralidad

- **Centralidad de nodo :** Grado
- **Centralidad de Cercanía:** ¿Y si no es tan importante tener muchos amigos directos? O estar "entre" otros. Pero uno sigue queriendo estar en el "medio" de las cosas, no demasiado lejos del centro.
 - La cercanía se basa en la longitud media del camino más corto entre un nodo y todos los nodos del grafo.
- **Centralidad de Intermediación:** ¿Cuántos pares de individuos tendrían que pasar por vos para llegar al otro en el mínimo número de saltos?

Centralidad de Cercanía

- Un nodo con alta centralidad de cercanía es aquel que puede llegar rápidamente a todos los demás. NO de tener muchas conexiones directas (centralidad de grado).

Ej: En una ciudad con muchas estaciones de tren, una estación con centralidad de cercanía alta es aquella desde la cual podés llegar rápido a cualquier otra, aunque no sea la más grande ni la que tiene más conexiones directas. Es eficiente para moverse.

- Cómo se calcula: Se suman las **distancias mínimas** desde ese nodo a todos los demás. Luego se toma el inverso de esa suma: cuanto menor sea la suma de distancias, mayor será la centralidad de cercanía.
- ¿Dónde y por qué es útil?
 - redes sociales: personas que difunden información muy rápido.
 - redes de insumo-producto: revela sectores estratégicos para la economía.
 - redes laborales: señala posiciones clave para la dinámica del empleo, la capacitación o la diseminación de shocks laborales.

Centralidad de Cercanía

- No dirigida, para nodo i , se calcula:


$$CC(i) = \frac{n - 1}{S(i)}$$

donde $S(i)$ es la suma de distancias, calculada a partir de las longitud del camino más corto entre los nodos

$$S(i) = \sum_{j \in V(G)} d(i, j)$$

Centralidad de Cercanía

- Ejemplo:



the distance matrix of this network, which is given by

$$D = \begin{bmatrix} 0 & 1 & 1 & 1 & 2 & 1 & 1 & 2 & 3 & 3 \\ 1 & 0 & 1 & 2 & 3 & 2 & 2 & 3 & 4 & 4 \\ 1 & 1 & 0 & 1 & 2 & 2 & 2 & 2 & 3 & 3 \\ 1 & 2 & 1 & 0 & 1 & 2 & 2 & 1 & 2 & 2 \\ 2 & 3 & 2 & 1 & 0 & 1 & 2 & 2 & 3 & 3 \\ 1 & 2 & 2 & 2 & 1 & 0 & 1 & 3 & 4 & 4 \\ 1 & 2 & 2 & 2 & 2 & 1 & 0 & 3 & 4 & 4 \\ 2 & 3 & 2 & 1 & 2 & 3 & 3 & 0 & 1 & 1 \\ 3 & 4 & 3 & 2 & 3 & 4 & 4 & 1 & 0 & 2 \\ 3 & 4 & 3 & 2 & 3 & 4 & 4 & 1 & 2 & 0 \end{bmatrix}$$

- The vector of distance-sum of each node is then

$$s = De = (e^T D)^T = [15 \ 22 \ 17 \ 14 \ 19 \ 20 \ 21 \ 18 \ 26 \ 26]^T$$

- For node 1 : $CC(1) = \frac{10-1}{s(1)} = \frac{9}{15} = 0,6$

- The full vector of closeness centralities is:

$$CC = [0.600 \ 0.409 \ 0.529 \ \mathbf{0.643} \ 0.474 \ 0.450 \ 0.428 \ 0.500 \ 0.346 \ 0.346]^T$$

Centralidad de Intermediación

- Un nodo con alta centralidad de intermediación es clave para conectar partes de la red que no estarían directamente conectadas. Si se elimina, podría fragmentar la red e interrumpir el flujo de información. En situaciones de crisis o difusión de información, estos nodos tienen gran poder de influencia.

Ej: En un conjunto de ciudades conectadas por carreteras, si una ciudad está ubicada en el punto de cruce entre muchas otras ciudades, entonces, muchos viajes entre otras ciudades necesariamente deben pasar por ella. Esta ciudad tendría una alta centralidad de intermediación, porque está facilitando la comunicación entre otras.

- Cómo se calcula: mide cuánto "puente de información" es un nodo en una red, cuántos caminos más cortos entre otros nodos pasan a través de él, y se calcula sumando estas fracciones para todos los pares de nodos en la red.
- ¿Dónde y por qué es útil?
 - redes sociales: estos nodos facilitan el paso de información entre otros grupos.
 - redes financieras: estos nodos conectan actores financieros, facilitando el flujo de capital e información y estabilizando la red.
 - redes laborales: estos nodos conectan diferentes grupos o sectores laborales, facilitando la comunicación, el intercambio de recursos o la colaboración entre ellos.

Centralidad de Intermediación

- No dirigida: para el nodo i , se calcula de la siguiente forma:

$$BC(i) = \sum_j \sum_k \frac{\rho(j,i,k)}{\rho(j,k)}, i \neq j \neq k$$

- donde $\rho(j,k)$ es el número total de caminos más cortos entre nodos j y k
- $\rho(j,i,k)$ es el número de caminos más cortos entre j y k que pasan por el nodo i

Trabajo en grupos

Explorando Redes con igraph

- **Dataset**

```
library(igraph)
library(igraphdata)
data(NOMBRE DEL DATASET) # cada grupo reemplaza por el dataset
distinto
g <- NOMBRE DEL DATASET
```

- **Temáticas:**

- `data(package = "igraphdata")$results[, "Item"]`
- Si su dataset es foodwebs, recuerden que es una colección de redes: primero elijan una con `g <- foodwebs$ChesLower`

- **Presentación:** 3 hallazgos

- **Característica de la red**
 - ¿Cuántos nodos y aristas tiene? `summary(g)`
 - ¿Qué atributos tienen los nodos y las aristas? Es dirigida o no dirigida? Es ponderada o no ponderada?
 - ¿La red está conectada? Si no, ¿cuántos componentes tiene y qué tamaño tiene el más grande?
- **Cómo se conecta**
 - Grado promedio y la mediana; Son parecidos o muy distintos? Qué dice eso sobre la red?
 - Histograma de grados. Tiene cola larga?
 - Cuáles son los 5 nodos más conectados (hubs?) Tiene sentido que sean hubs?
 - Densidad? Es una red densa o esparsa?
- **Estructura de la red**
 - Coeficiente de clustering global. Es alto o bajo?
 - Cuál es la distancia promedio entre nodos?
 - Cuántas comunidades encontró
 - # Detección de comunidades (convertir a no dirigida si hace falta):
 - `com <- cluster_louvain(as.undirected(g))`
 - `length(com)`
 - `sizes(com)`

Actividad Grupal: Puesta en común

Dataset	Nodos	Links	$\langle k \rangle$	$\langle d \rangle$	C	Hubs?	N°Com

TAREA

- Comparar el ranking de distintas métricas de centralidad para el Karate
 - Ordenar los nodos según distinta métrica (Grado, Cercanía, Intermediación)
 - Qué nodos aparecen como importantes en todas las métricas? Cuáles solo en alguna?
 - Cruzar los resultados con lo que pasó en la vida real: el club se dividió en dos.
 - **Pregunta:** las métricas permiten anticipar la división? Qué nodo podría haber funcionado como mediador?

Referencia **igraph** y otros

- [Manual de referencia R](#)
- [Cheat sheet](#)
- R tidyverse related packages
 - [ggraph](#)
 - [tidygraph](#)